

2023 年度 卒業論文

# MI-EEG の一人称および三人称視 点の手の動作イメージの分析比較

指導教員 北野 勝則 教授

立命館大学  
情報理工学部情報理工学科

BANG Hyunmin

2024 年 1 月

## 概要

本研究では、1人称視点（被験者と同じ視点）と3人称視点（被験者の後方視点）でのMI-EEG（Motor Imagery Electroencephalography）を通じて手の動きイメージに対するC3とP3脳領域の活性化の違いを調べた。データ前処理はバンドパスフィルタを使用し、特徴抽出方法としてWaveletを利用し、モデルはMLPを選択した。結果としてクラス3（3人称）がクラス1（1人称）よりも高い分類性能を示していることを確認することができた。

# 目次

第 1 章	研究の背景と目標と関連研究	2
1.1	研究の背景 . . . . .	2
1.2	目標 . . . . .	2
1.3	関連研究 . . . . .	3
第 2 章	研究方法	4
2.1	測定方法 . . . . .	5
2.2	データの前処理 . . . . .	5
2.3	評価方法 . . . . .	5
第 3 章	特徴抽出選択	8
3.1	特徴抽出方法の比較 . . . . .	8
第 4 章	モデル選択	15
4.1	モデル性能 . . . . .	15
4.2	Wavelet + MLP モデルの解釈 . . . . .	17
4.3	ROC curve 比較 . . . . .	18
第 5 章	結論	20
5.1	結論と考察 . . . . .	20

# 第 1 章

## 研究の背景と目標と関連研究

### 1.1 研究の背景

過去の研究では、BCI (Brain Computer Interface) で用いられる MI-EEG (Motor Imagery EEG) は主に 1 人称視点での動きのイメージを研究するために使用されてきた (Ruby & Decety、2001) [10]。これまでの研究から得られた知見に基づいて、本研究は MI-EEG を用いて手の動作イメージをより詳細に探究し、具体的には 1 人称視点と 3 人称視点の差を比較的に分析することを目指している。

具体的な背景として、Ruby と Decety (2001) [10] の研究は、1 人称視点と 3 人称視点の脳内の特定部分の活性化の違いに焦点を当てているが、この先行研究による知見は 1 人称視点と 3 人称視点を測定する上でどちらが優れているかを判断するには限界があり、また、1 人称視点と 3 人称視点における脳内処理の違いについても解明されていない。

### 1.2 目標

したがって、本研究では、MI-EEG を用いて 1 人称視点と 3 人称視点で手の動作イメージを詳細に測定し、これに基づいてどの時点が MI-EEG 測定に適しているかを明らかにすることが主な目的である。この比較は、手の動作イメージの脳内処理の理解を深め、BCI 技術の発展に新たな知見を提供することを期待している。例えば、腕がない人が脳波で作動する義手で右腕を動かしたいときに一人称視点で想像するか、または、三人称視点で想像するかを選択するとき本研究を参考にすることができると期待している。

## 1.3 関連研究

Ruby と Decety (2001) [10] の研究によると、1 人称視点では左下頭頂小葉 (left inferior parietal lobule) と 体性感覚野 (somatosensory cortex) で強い活性化が見られ、3 人称時点では precuneus、左後帯状皮質 (left posterior cingulate cortex)、right frontopolar gyrus で特定の活性化が検出された。

## 第 2 章

# 研究方法




Figure 2. Electrode positions and labels in the 10 ± 20 system [8].

出典：Mahsa Soufineyestani et al(2020) p.3

図2.1 Mahsa Soufineyestani et al、(2020)に基づく 10-10 system の図

[4]

本研究では、参加者に右腕を曲げたり伸ばしたりする動作を1人称視点と3人称視

点でイメージし、それを測定して比較分析した。使用された電極は c3 と p3 で、c3 を選択した理由は、Kim と Lee (2023) [7] によると、Somatosensory cortex で脳波を測定するとき、通常 C3、Cz、C4 チャンネルを使用することが効果的である。この位置は sensorimotor cortex を代表する電極位置であり、Somatosensory cortex で発生した脳波を正確に測定することが理由である。また、p3 を選択した理由は、Scrivener と Reader(2023) [8] によると、P3 と P4 電極が precuneus に投影されることが理由である。本研究では右腕を用いたため、右に関連する左脳の c3 と p3 を中心に分析を行った。

## 2.1 測定方法

実験は 20 代男性 9 人の参加者に Psychopy を使用して行われ、以下の通りである。

1. 被験者は 1 人称視点で右腕を曲げたり伸ばしたりする動作映像を 5 秒間見る。
2. 映像が終わった後に被験者は 1 人称視点で右腕を曲げたり伸ばしたりする一回の動作を 5 秒間イメージする。
3. 1, 2 の過程を 20 回繰り返す。
4. 被験者は 3 人称視点で右腕を曲げたり伸ばしたりする動作映像を 5 秒間見る。
5. 映像が終わった後に被験者は 3 人称視点で右腕を曲げたり伸ばしたりする一回の動作を 5 秒間イメージする。
6. 4, 5 の過程を 20 回繰り返す。

## 2.2 データの前処理

データファイルから「EEG.C3」と「EEG.P3」のデータを抽出し、「上肢運動を行う過程で、運動皮質領域の脳波はミューリズム (mu rhythm、8~14Hz) とベータリズム (beta rhythm (15~30 Hz) で活性化される」(Kwon GH et al., 2013) [3] に基づいて、生のデータから通過帯域内で可能な限り平坦な周波数応答を持つように設計されている信号処理フィルターの一種である Butterworth フィルタで、Butterworth フィルターの一種であるバンドパスフィルタを使用して 8Hz~30Hz の周波数範囲をフィルタリングした。

## 2.3 評価方法

分類性能を評価する方法としては、以下の基準で従う。

本研究は二項分類研究で、クラス 3 (3 人称) が陽性クラスであり、クラス 1 (1 人

称) が陰性クラスである

正解率 (Accuracy) :

- 正解率は、サンプル全体の正確に分類されたサンプルの割合を示す。

- 正解率 (accuracy) =  $(TP + TN) / (TP + TN + FP + FN)$

精度 (Precision) :

- 精度は、モデルが陽性として予測したサンプルのうち、実際に陽性であるサンプルの割合を表す。

- 精度 (precision) =  $TP / (TP + FP)$

再現率 (Recall) :

- 再現率は、実際に陽性クラスであるサンプルのうち、モデルが正確に陽性クラスとして予測したサンプルの割合を表す。

- 再現率 (recall) =  $TP / (TP + FN)$

F1 スコア (F1-Score) :

- F1 スコアは、精度と再現率の調和平均として計算される。

- F1 スコア =  $2 * (\text{精度} * \text{再現率}) / (\text{精度} + \text{再現率})$

T = True , F = False , P = Positives , N = Negatives

TP (True Positives): モデルが正しく陽性クラスを予測したサンプルの数。

FP (False Positives): モデルが誤って陽性クラスとして予測したが、実際は陰性クラスであるサンプルの数。

FN (False Negatives): モデルが誤って陰性クラスとして予測したが、実際は陽性クラスであるサンプルの数。

TN (True Negatives): モデルが正しく陰性クラスを予測したサンプルの数

Support :

- 特徴抽出方法を経て出てきた各クラスの特徴量の数 (テストデータの数全体の 20% であるため全体特性ベクトルの 20% になる)



マクロ平均 (Macro avg)：クラス別の値を平均した結果、Support の値が同じまたは小さいときに使用する。

重み付け平均 (Weighted avg)：クラス別の値の重み付け平均した結果、Support の値が同じまたは大きいときに使用する。

## 第 3 章

# 特徴抽出選択

### 3.1 特徴抽出方法の比較

特徴抽出方法としては Wavelet と FFT を比較して、与えられた EEG データセットの効果的な特徴抽出方法を見つけた。特徴抽出方法としては Wavelet と FFT（高速フーリエ変換、Fast Fourier Transform）を比較して、測定した EEG データの効果的な特徴抽出方法を見つける。

「ウェーブレット関数は、ターゲット信号を低周波帯域フィルタを介して詳細係数(detail coefficient) と高周波帯域フィルタを介して近似係数 (approximation coefficient) を生成する。」(Kyung-Min Lee , Chul-Won Park、2017)[6]

本研究で使った Wavelet は離散 Wavelet 変換であり、その中でも db1 (Wavelet Daubechies 1) を使っている。

「結局、離散型ウェーブレット変換は、各スケール項と遷移項により以下の次式のようにになる。

$$f[t] = \sum_{k=-\infty}^{\infty} a_{j,k} \phi_{j,k}(t) + \sum_{J=1}^J \sum_{k=-\infty}^{\infty} d_{j,k} \psi_{j,k}(t)$$

ここで、Jは最終波形分解ステップを意味し、最大分解ステップによって導出された係数である a は最も低い周波数成分、すなわち最も広いスケール領域を表し、d は最大分解ステップの前の各ステップにおける周波数成分に対する係数」(Chang Ryeol Oh et al、2010)[1]

DB1(Wavelet Daubechies 1) は J が 1 の時である。

最終分解された近似係数 (a) と詳細係数 (d) のウェーブレット変換結果で特徴ベクトルを作る。

例えば、本実験のウェーブレット変換した特徴ベクトルの中で、一つの特徴ベクトルは {Label 1 or 3(1人称または3人称)、(C3の近似成分、C3の詳細成分、P3の近似成分、P3の詳細成分)} で構成されている。

「時間の領域を周波数領域に変換することができ、これをフーリエ変換と呼ぶ。すなわち、波をフーリエ変換した結果がその波を構成する周波数である。このようにフーリエ変換を使って周波数を分析することをフーリエ解析と呼ぶ。進歩した技術である高速フーリエ変換 (FFT) は、コンピュータを用いて離散的なデータを高速にフーリエ変換する方法である。」(Kim Chaewon et al., 2019)[2] に基づいて FFT を使って特徴ベクトルを抽出した。

例えば、本実験の FFT した特徴ベクトルの中で、一つの特徴ベクトルは {Label 1 or 3(1人称または3人称)、(C3の周波数成分のコサイン値、C3の周波数成分のサイン値、P3の周波数成分のコサイン値、P3の周波数成分のサイン値)} で構成されている。

1人称と3人称の特徴をモデルに入れて分析する。

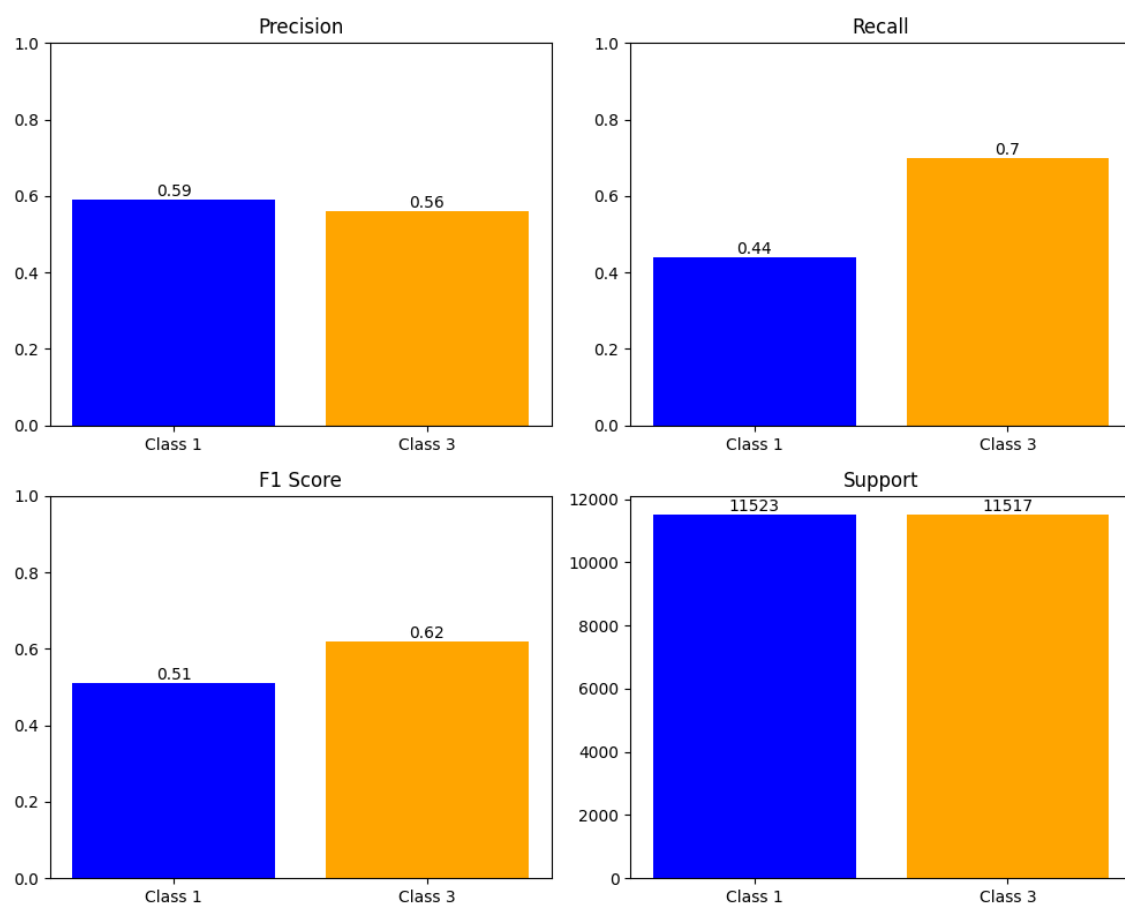


図3.1 Wavelet 特徴抽出法の比較.




図3.2 FFT 特徴抽出法の比較.

X 軸: 性能指標

グラフの X 軸は、「Precision」、「Recall」、「F1-Score」および「Support」、という 4 つの主要な性能指標を表している。

Y 軸: 性能指標の値

グラフの Y 軸は、該当する性能指標の値であり、青い棒は Class 1 を示し、オレンジ色の棒は Class 3 を示す。

図3.1と図3.2は、Wavelet 変換と FFT (Fast Fourier Transform) 特徴抽出方法を用いて学習した MLP (Multi-Layer Perceptron) モデルの性能を比較した結果である。性能は、Accuracy、Precision、Recall、F1-Score および Support で評価された。




図 1 MLPモデルの一般構造

出典：張 立堅, 星 仰 (1996) p.28

図3.3 張 立堅, 星 仰, (1996) に基づく MLP モデルの一般構造 [11]

MLP は訓練データから学習し、未知のデータに対する予測を行う。構造は入力層 (Input Layer)、隠れ層 (Hidden Layer)、出力層 (Output Layer) ごとに層 (Layer) 分けされた多層構造で、各層間のパーセプトロンは全て互いに結合している全結合型 (Fully Connected) ニューラルネットワークである。本研究では、特徴抽出した各特徴量が入力ニューロンに対応し、それぞれの値がネットワークに輸入され、隠れ層が 1 つで 1000 個のニューロンを持つ構造で、出力層でネットワークの出力が生成される。

二つのグラフを比較分析するとき Support を見ると、両特性抽出方法の Support が同じまたは差が少ないことが分かる。したがって、比較するときにはマクロ平均を

使用する。




図3.4 macro avg の Wavelet 変換 vs FFT の性能指標.

図3.4を見て比較すると、Wavelet + MLP の Accuracy が 0.57 で、FFT + MLP の Accuracy が 0.52 に対比して高いことが分かる。Precision、Recall、F1-Score の各指標でも Wavelet + MLP が優れており、特に Precision が 0.57 と高いため、モデルがクラスを正確に判別する優れた性能を示している。これらの結果は、本実験で測定した EEG データからの Wavelet 特徴抽出が非線形性を考慮してモデルに適していることを示唆している。



## 第 4 章

# モデル選択

### 4.1 モデル性能

本研究では、測定した EEG データセットの効果的な分類モデルを選択するために二つのモデルを比較する実験を行った。当初はランダムフォレスト (RandomForest) を検討した。ランダムフォレストはアンサンブルモデルの一種であり、パターン認識をはじめとして、回帰、クラスタリングに利用できる (HITOSHI HABE、2012) [5]MLP と比較したの結果、MLP がより優れた性能を示した。

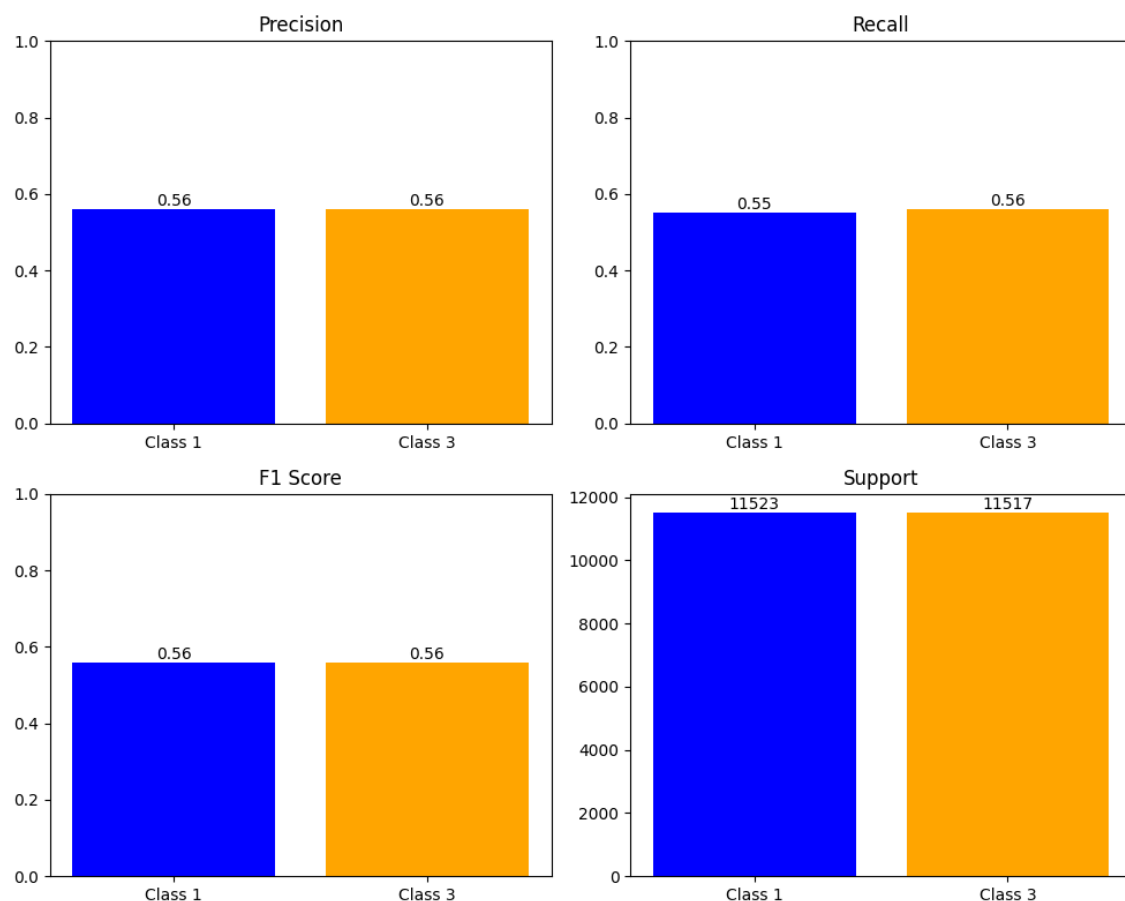


図4.1 Wavelet + Random Forest の比較.

#### 図4.1の説明

X 軸: 性能指標

グラフの X 軸は、「Precision」、「Recall」、「F1-Score」および「Support」、という 4 つの主要な性能指標を表している。

Y 軸: 性能指標の値

グラフの Y 軸は、該当する性能指標の値であり、青い棒は Class 1 を示し、オレンジ色の棒は Class 3 を示す。

章6 モデル選択では 5 章で説明した Wavelet + MLP と Wavelet + Random Forest を比較分析を行う。二つのグラフを比較分析するときに Support を見ると、モデル Support の差が少ないことが分かる。したがって、比較するときにはマクロ平均を使用する。




図4.2 macro avg の MLP vs. Random Forest の比較.

図4.2と Accuracy を見て比較すると、

Accuracy 比較:

ランダムフォレストの Accuracy は 0.56 であり、MLP の Accuracy は 0.57 であった。MLP は比較的高い正解率を達成した。実際の現場のデータに対してモデルが有効であることを示唆している

Precision, Recall, F1-Score 、Support 比較:

F1-Score 、Support は同じであるが、MLP の Precision、Recall はランダムフォレストに比べて高いである。Precision が高いのは、モデルが誤って陽性と予測するケースが少ないことを示し、Recall が高いのは、モデルが実際の陽性サンプルをランダムフォレストに比べて正確に見つけ出している

## 4.2 Wavelet + MLP モデルの解釈

総合的に Wavelet + MLP モデルが最も優れていつことが明らかになった。したがって、図3.1の Wavelet + MLP を使ってクラス1とクラス3のどちらがもっと分類ができるかについて調べる。

適合率 (Precision):

クラス 1 の場合: 0.59

クラス 3 の場合: 0.56

適合率でみると、クラス 1 が微妙な差でクラス 3 より高いことが分かる。これは、モデルがクラス 1 をクラス 3 より誤って予測するケースが少ないことを意味する。

再現率 (Recall):

クラス 1 の場合: 0.44

クラス 3 の場合: 0.70

再現率でみると、モデルが実際のクラス 3 サンプルをクラス 1 に比べて正確に見つけ出していることが分かる。

F1 スコア (F1-Score):

クラス 1 の場合: 0.51

クラス 3 の場合: 0.62

F1 スコアで見ると、モデルのバランスの部分でクラス 3 がクラス 1 より優れていることが分かる。

総じて、この結果を見ると、クラス 3 の方がクラス 1 よりも再現率、F1 スコアが高いことがわかる

## 4.3 ROC curve 比較

現在のモデルの「Accuracy」、「Precision」、「Recall」、「F1-Score」および「Support」は高い数値でない、したがって、モデルが意味があるモデルなのかを判別する必要がある。ROC Curve は、実際の陽性の中でモデルが陽性で予測した割合 (TPR) と実際の陰性の中でモデルが陽性で誤って予測した割合 (FPR) を表す曲線です。




図4.3 Wavelet + MLP モデルの ROC curve.

モデルの ROC curve を計算してみると、0.60 である

「通常、AUC 数値に応じて非情動的 (AUC=0.5)、あまり正確ではない ( $0.5 < \text{AUC} < 0.7$ )、中等度の正確 ( $0.7 < \text{AUC} < 0.9$ )、非常に正確な ( $0.9 < \text{AUC} < 1$ )、完全な検査 (AUC= 1) として分類できます。」(Sang Wook Song, 2009)[9] に基づいてみると、本研究のモデルは意味があるモデルである。

## 第 5 章

# 結論

### 5.1 結論と考察

本研究では、前処理された MI-EEG データを使用して、1 人称視点および 3 人称視点での手運動イメージを分類した。得られた結果から見ると、本研究のモデルは意味があるモデルで、Accuracy が 0.57 となり、特に 3 人称視点の方が 1 人称視点よりも高い分類性能を示している。適合率は似ているが再現率、F1 スコアは 3 人称視点が高いため、統計的に優れていることが確認された。これにより、MI-EEG を用いた手の動作イメージの測定において、3 人称視点の方がより適していることが示唆される。

# 参考文献

- [1] Chang Ryeol Oh et al. A study on noise reduction method by wavelet transform. *Proceedings of the Korea Water Resources Association Conference*, (05a):27–32, 2010.
- [2] Kim Chaewon et al. Effects and limitations of separating overlapped fingerprints using fast fourier transform. *Korean Security Management Association*, 61(12):377–400, 2019.
- [3] Kwon GH et al. Connectivity analysis between eeg and emg signals by the status of movement intention. *Korean Society for Emotion and Sensibility*, 19(1):31–38, 2016.
- [4] Mahsa Soufineyestani et al. Electroencephalography (eeg) technology applications and available devices. *Applied Sciences*, 10(21):7453, 2020.
- [5] HITOSHI HABE. Random forests. *IPSJ SIG Technical Report*, 2012(31):182, 2012.
- [6] Chul-Won Park Kyung-Min Lee. A study on fault detection for transmission line using discrete daubechies wavelet transform. *The Transactions of the Korean Institute of Electrical Engineers*, 66(1):27–32, 2017.
- [7] Kim S and Lee O. Immediate effect on mu-rhythm of somatosensory cortex using visual feedback training in healthy adults. *Journal of The Korean Society of Physical Medicine*, 18(3):47–53, 2023.
- [8] CL Scrivener and AT Reader. Variability of eeg electrode positions and their underlying brain regions: visualizing gel artifacts from a simultaneous eeg-fmri dataset. *Journal of Clinical Neurophysiology*, 34(2):107–113, 2023.
- [9] Sang Wook Song. Using the receiver operating characteristic (roc) curve to measure sensitivity and specificity. *Korean J Fam Med*, 30(11):841–842, 2009.
- [10] Ruby, P., and Decety, J. Effect of subjective perspective taking during simulation of action: a pet investigation of agency. *Nature Neuroscience*, 4(5):546–550, 2001.

- [11] 星 仰 張 立堅. 衛星画像データ分類用 mlp モデルの学習率の設定. *J-STAGE*, 35(1):27–35, 1996.